

01강

서울대학교 통계학과 이재용 교수

베이지안 통계학

베이지 추론의 기본 개념





목차

01 베이지 추론의 아버지
: 베이지와 라플라스


02 베이지 추론



01 베이즈 추론의 아버지 : 베이즈와 라플라스

토마스 베이즈(Thomas Bayes)

- * 토마스 베이즈는 1702년에 태어나 1761년 4월 17일에 사망하였다.
- * 베이즈는 영국 장로교 목사이자 아마추어 수학자였다.
- * 흄(David Hume)은 인과관계를 인간이 파악할 수 있다는 믿음을 의심했다.
이에 대한 반박으로 베이즈는 논문을 썼다.



피에르 시몬 라플라스(Pierre-Simon Laplace)

- ★ 라플라스는 1749년 3월 23일
노르망디의 작은 마을에서 태어나고,
1827년 3월 5일에 78세를 일기로
사망하였다.
- ★ 태양계의 안정성 문제를 확률로
다룰 수 있다고 생각하고,
확률에 대한 연구를 시작하였다.



라플라스의 업적

- ▣ 베이즈 정리의 재발견: 원인의 확률이라는 개념 발견.
- ▣ 중심극한정리(Central Limit Theorem)의 발견
- ▣ 남녀출생성비의 계산
- ▣ “나는 그 가설이 필요하지 않습니다.”

02 베이지 추론



베이지안 추론의 3가지 요소

- **사전분포** 모수 θ 의 분포로서 자료를 보기 전의 분석자의 θ 에 관한 지식을 표현한다.

$$\theta \sim \pi(\theta)$$

- **모형 혹은 가능도**

$$x | \theta \sim f(x | \theta)$$

- **사후분포** 자료 x 가 주어졌을 때, θ 의 조건부분포.

자료를 본 후에 분석자의 θ 에 관한 지식을 나타낸다.

$$\theta | x \sim \pi(\theta | x)$$

[$\cdot | \cdot$]기호: [x]는 x 의 분포를, [$x|\theta$]는 θ 가 주어졌을 때 x 의 분포를 나타낸다.



베이즈규칙

▣ 베이즈 규칙 혹은 베이즈 정리는 사후분포를 구하는 공식이다.

▣ 공식

$$\pi(\theta|x) = \frac{\pi(\theta) \cdot f(x|\theta)}{m(x)}.$$

여기서 $m(x) = \int \pi(\theta) \cdot f(x|\theta) d\theta$ 는 x 의 주변분포 밀도함수이다.

▣ 해석

$$\pi(\theta|x) \propto \pi(\theta) \cdot f(x|\theta)$$

사후분포 $\propto$ 사전분포 x 가능도

▣ 충분통계량과 사후분포

T 가 θ 에 대한 충분통계량일 때, $[\theta|x] = [\theta|T(x)]$. 즉,

$$\begin{aligned} \pi(\theta|x) &= \pi(\theta|T(x)) \\ &= \frac{\pi(\theta) \cdot g(T(x)|\theta)}{m(T(x))}. \end{aligned}$$

여기서 $g(t|\theta)$ 는 T 의 밀도함수이고, $m(t)$ 는 T 의 주변밀도함수이다.

이항모형

- 사전분포 $\theta \sim \text{Beta}(\alpha, \beta), \alpha, \beta > 0$
- 모형 $x|\theta \sim \text{Bin}(n, \theta)$
- 사후분포 $\theta|x \sim \text{Beta}(\alpha + x, \beta + n - x), x = 0, 1, \dots, n.$
- 베이즈 추정량은 사전분포의 평균과 최대가능도 추정량의 가중평균이다.

$$\hat{\theta}^B = \mathbb{E}(\theta|x) = \frac{\alpha + \beta}{\alpha + \beta + n} \frac{\alpha}{\alpha + \beta} + \frac{n}{\alpha + \beta + n} \frac{x}{n}.$$

$$\mathbb{E}(\theta) = \frac{\alpha}{\alpha + \beta}, \quad \hat{\theta}^{MLE} = \frac{x}{n} \text{ 이다.}$$

- 표본의 크기가 커지면서 사전분포는 사라진다. 즉 자료가 사전분포를 압도한다.

$$\lim_{n \rightarrow \infty} \hat{\theta}^B = \hat{\theta}^{MLE}.$$

- 사전분포 파라미터의 결정 $\alpha + \beta$ 를 사전표본의 크기로 해석한다.

균등사전분포와 불충분근거의 원칙

θ 에 대한 사전분포로

$$\theta \sim U(0, 1)$$

를 많이 사용한다.

- 라플라스는 균등분포가 완전한 무지를 표현한다고 생각했다.
- 불충분근거의 원칙이란 근거가 없는 경우 두 개의 다른 사건은 동일한 사전 확률을 갖는다는 원칙이다.
- 베이즈는 균등분포를 사전분포로 쓸 때, x 의 주변분포가 이산균등분포가 되는 것을 보고 $U(0, 1)$ 을 사전분포로 써야하는 이유라고 생각했다.
- $\theta \sim U(0, 1) = \text{Beta}(1, 1), x|\theta \sim \text{Bin}(n, \theta)$ 이면,
 $\theta|x \sim \text{Beta}(x + 1, n - x + 1)$ 이다.

정규모형 : 평균을 모르고 분산은 아는 경우

□ 모형

σ^2 은 아는 값이고, θ 에 대해 추론하고자 한다.

$$X_1 \cdots X_n | \theta \stackrel{i.i.d.}{\sim} N(\theta, \sigma^2)$$

□ 사전분포 $\theta \sim N(\mu, \tau^2)$

□ 사후분포

$$\theta | x \sim N\left(\frac{\frac{n}{\tau^2}\mu + \frac{n}{\sigma^2}\bar{x}}{\frac{1}{\tau^2} + \frac{n}{\sigma^2}}, \frac{1}{\frac{1}{\tau^2} + \frac{n}{\sigma^2}}\right).$$

여기서 $x = (x_1, \dots, x_n)$ 이다.

□ 베이즈 추정량은 사전분포의 평균과 최대 가능도추정량의 가중 평균이다.

$$\begin{aligned} \hat{\theta}^B &= \frac{\frac{1}{\tau^2}\mu + \frac{n}{\sigma^2}\bar{x}}{\frac{1}{\tau^2} + \frac{n}{\sigma^2}} \\ &= \frac{\frac{1}{\tau^2}}{\frac{1}{\tau^2} + \frac{n}{\sigma^2}} \mu + \frac{\frac{n}{\sigma^2}}{\frac{1}{\tau^2} + \frac{n}{\sigma^2}} \bar{x}. \end{aligned}$$

여기서 μ 는 사전분포의 평균이고 $\bar{x}$ 는 $\hat{\theta}^{MLE}$ 이다.

□ 관측치의 개수가 커지면서, 자료가 사전분포를 압도한다. 즉

$$\lim_{n \rightarrow \infty} \hat{\theta}^B = \hat{\theta}^{MLE}.$$

□ 사전분포 모수의 결정

$\tau^2 = \sigma^2 / k$ 라 놓을때, k 를 사전표본의 개수라 한다.

□ 점근적으로 사후분포와 최대가능도추정량의 분포가 동일하다.

$\theta \in \mathbb{R}$ 에 대한 균등분포

□ 균등사전분포일 때의 사후분포

$$\theta \sim \pi(\theta) = 1, \forall \theta \in \mathbb{R}$$

균등분포 $\pi(\theta)$ 는 엄밀한 의미에서 확률분포가 아니다.
그럼에도 불구하고, 사후분포를 계산해보면

$$\theta|x \sim N\left(\bar{x}, \frac{\sigma^2}{n}\right)$$

으로, 자료가 사전분포를 압도한 사후분포의 값으로 합리적이다.

□ 균등사전분포일 때의 사후분포는 어떤 사전분포의 사후분포들의 극한이다.

$$\lim_{\tau^2 \rightarrow \infty} [\theta|x]_{\pi} = [\theta|x]_{\pi(\theta)=1}.$$

감마분포로 정의 되는 분포들

□ 감마분포 $X \sim \text{Ga}(\alpha, \beta), \alpha, \beta > 0$.

★ 밀도함수: $f(x) = \frac{\beta^\alpha}{\Gamma(\alpha)} x^{\alpha-1} e^{-\beta x}, x > 0$

★ $\mathbb{E}X = \frac{\alpha}{\beta}, \text{Var}(X) = \frac{\alpha}{\beta^2}$.

□ 카이제곱분포 $X \sim \chi^2(v) = \text{Ga}\left(\frac{v}{2}, \frac{1}{2}\right)$.

★ 밀도함수: $f(x) = \frac{\left(\frac{1}{2}\right)^{\frac{v}{2}}}{\Gamma\left(\frac{v}{2}\right)} x^{\frac{v}{2}-1} e^{-\frac{1}{2}x}, x > 0$.

★ $\mathbb{E}X = v, \text{Var}(X) = 2v$.

□ 척도 카이제곱분포 $X \sim \chi^2(v, \lambda) = \text{Ga}\left(\frac{v}{2}, \frac{v}{2}\lambda\right)$.

★ 밀도함수: $f(x) = \frac{\left(\frac{v\lambda}{2}\right)^{\frac{v}{2}}}{\Gamma\left(\frac{v}{2}\right)} x^{\frac{v}{2}-1} e^{-\frac{v\lambda}{2}x}, x > 0$.

★ $\mathbb{E}X = \frac{1}{\lambda}, \text{Var}(X) = \frac{2}{v\lambda^2}$.

□ 역감마분포 $X \sim \text{Inv-Ga}(\alpha, \beta) \Leftrightarrow 1/X \sim \text{Ga}(\alpha, \beta), \alpha, \beta > 0$.

★ 밀도함수: $f(x) = \frac{\beta^\alpha}{\Gamma(\alpha)} \left(\frac{1}{x}\right)^{\alpha+1} e^{-\beta/x}, x > 0$

★ $\mathbb{E}X = \frac{\beta}{\alpha-1}, \alpha > 1$.

★ $\text{Var}(X) = \frac{\beta^2}{(\alpha-1)^2(\alpha-2)}, \alpha > 2$.

□ 역카이제곱분포 $X \sim \text{Inv-}\chi^2(v) = \text{Inv-Ga}\left(\frac{v}{2}, \frac{1}{2}\right)$

★ 밀도함수: $f(x) = \frac{\left(\frac{1}{2}\right)^{\frac{v}{2}}}{\Gamma\left(\frac{v}{2}\right)} \left(\frac{1}{x}\right)^{\frac{v}{2}+1} e^{-\frac{1}{2x}}, x > 0$.

★ $\mathbb{E}X = \frac{1}{v-2}, v > 2$

★ $\text{Var}(X) = \frac{2}{(v-2)^2(v-4)}, v > 4$.

□ 역척도 카이제곱분포 $X \sim \text{Inv-}\chi^2(v, \lambda) = \text{Inv-Ga}\left(\frac{v}{2}, \frac{v}{2}\lambda\right)$.

★ 밀도함수: $f(x) = \frac{\left(\frac{v\lambda}{2}\right)^{\frac{v}{2}}}{\Gamma\left(\frac{v}{2}\right)} \left(\frac{1}{x}\right)^{\frac{v}{2}+1} e^{-\frac{v\lambda}{2x}}, x > 0$.

★ $\mathbb{E}X = \frac{v}{v-2}\lambda, v > 2$

★ $\text{Var}(X) = \frac{2v^2\lambda^2}{(v-2)^2(v-4)}, v > 4$.

정규모형 : 평균을 알고 분산에 대해 추론하는 경우

□ 모형

θ 는 아는 값이고, $\sigma^2 > 0$ 에 대해 추론하고자 한다.

$$X_1, \dots, X_n | \sigma^2 \stackrel{i.i.d.}{\sim} N(\theta, \sigma^2)$$

□ 사전분포

$$\sigma^2 \sim \text{Inv-}\chi^2(v_0, \sigma_0^2)$$

$$\Leftrightarrow \tau^2 = \frac{1}{\sigma^2} \sim \chi^2(v_0, \sigma_0^2) = \text{Ga}\left(\frac{v_0}{2}, \frac{v_0 \sigma_0^2}{2}\right)$$

□ 사후분포

$$\tau^2 | x \sim \chi^2\left(v_n = v_0 + n, \sigma_n^2 = \frac{v_0 \sigma_0^2 + n s^2}{v_n + n}\right)$$

혹은 $\sigma^2 | x \sim \text{Inv-}\chi^2(v_n, \sigma_n^2)$

$$\text{여기서 } s^2 = \frac{1}{n} \sum_{i=1}^n (x_i - \theta)^2.$$

참고문헌

1. 이금희 외 4인. 통계학의 개념 및 제문제 9장 2절.
한국방송통신대학교출판부, 2011.
2. Berger, James O. Statistical decision theory and Bayesian analysis의
4장 2절. Springer Science & Business Media, 2013.



수고하셨습니다.

감사합니다.

