

03강

서울대학교 통계학과 이재용 교수

베이지안 통계학

베이지스 추정과 검정





목차

- 01 점추정
- 02 구간추정
- 03 가설검정

01 점추정



추정: 세 가지 사후분포의 한 점 요약

▣ 사후분포의 평균

$$\hat{\theta}^M := \mathbb{E}(\theta|x) = \int \theta \pi(\theta|x) d\theta.$$

▣ 사후밀도함수의 모드 혹은 최대값

$$\hat{\theta}^{MAP} := \underset{\theta}{\operatorname{argmax}} \pi(\theta|x).$$

▣ 사후분포의 중앙값

$$\hat{\theta}^{med} := \operatorname{med}^{\pi(\theta|x)}(\theta).$$

추정의 두 가지 예

▣ 이항모형

* 사전분포

$$\theta \sim \text{Beta}(\alpha, \beta), \alpha, \beta > 0$$

* 모형

$$x|\theta \sim \text{Bin}(n, \theta)$$

* 사후분포

$$\theta|x \sim \text{Beta}(\alpha + x, \beta + n - x),$$

$$x = 0, 1, \dots, n.$$

* 문제 : 세가지 추정량을 구해보자.

▣ 정규모형

* 모형

σ^2 은 아는 값이고, θ 는 모르는 값이다.

$$X_1, \dots, X_n | \theta \stackrel{i.i.d.}{\sim} N(\theta, \sigma^2)$$

* 사전분포

$$\theta \sim N(\mu, \tau^2)$$

* 사후분포

$$\theta|x \sim N\left(\frac{\frac{1}{\tau^2}\mu + \frac{n}{\sigma^2}\bar{X}}{\frac{1}{\tau^2} + \frac{n}{\sigma^2}}, \frac{1}{\frac{1}{\tau^2} + \frac{n}{\sigma^2}}\right).$$

여기서 $x = (X_1, \dots, X_n)$ 이다.

* 문제 : 세가지 추정량을 구해보자.

추정오차(estimation error)

- 추정치 δ 의 추정오차로 $E[((\delta - \theta)^2 | x)]$ 혹은 $\sqrt{E((\delta - \theta)^2 | x)}$ 를 쓴다.
이를 δ 의 사후분산 혹은 사후표준편차라 한다.
- 사후분포의 산포에 관한 측도로 사후분포의 분산과 표준편차를 쓴다.

사후분포가

$$\theta | X \sim N \left(\frac{\frac{1}{\tau^2} \mu + \frac{n}{\sigma^2} \bar{X}}{\frac{1}{\tau^2} + \frac{n}{\sigma^2}}, \left(\frac{1}{\tau^2} + \frac{n}{\sigma^2} \right)^{-1} \right)$$

와 같이 주어질 때, 사후분포의 분산과 표준편차를 구해보자,
또한 추정량 $\delta(x) = \bar{x}$ 의 사후분산을 구해보자.

02 구간추정



신용집합(credible set)

▣ $100(1-\alpha)\%$ 신용집합의 정의

집합 $C \subseteq \Theta$ 이 $\pi(C|X) \geq 1 - \alpha$ 를 만족하면 C 를 θ 의 $100(1 - \alpha) \%$, $0 \leq \alpha \leq 1$ 신용집합이라고 한다.

▣ 최고사후밀도(Highest posterior density, HPD) 신용집합

θ 의 $100(1 - \alpha)\%$ 최고사후밀도 신용집합 $C \subseteq \Theta$ 는 $C = \{\theta \in \Theta : \pi(\theta|X) \geq k\}$ 와 같이 정의된다.
여기서 k 는 $P(C|X) \geq 1 - \alpha$ 가 되도록 정해진다.

▣ 동일꼬리 신용집합(equal tail credible set)

θ 의 $100(1 - \alpha)\%$ 동일꼬리 신용집합은 $[A, B]$ 와 같이 정의되고, A, B 는
 $\pi(\theta \leq A|X) = \frac{\alpha}{2}$ 와 $\pi(\theta \geq B|X) = \frac{\alpha}{2}$ 을 만족한다.

신용집합(credible set): 정규모형의 예

□ 모형

σ^2 는 아는 값이고, θ 는 모르는 값이다.
 $X_1, \dots, X_n \mid \theta \stackrel{i.i.d.}{\sim} N(\theta, \sigma^2)$

□ 사전분포

$$\theta \sim N(\mu, \tau^2)$$

□ 사후분포

$$\theta \mid X \sim N\left(\frac{\frac{1}{\tau^2}\mu + \frac{n}{\sigma^2}\bar{X}}{\frac{1}{\tau^2} + \frac{n}{\sigma^2}}, \frac{1}{\frac{1}{\tau^2} + \frac{n}{\sigma^2}}\right).$$

여기서 $X = (X_1, \dots, X_n)$ 이다.

□ 문제

θ 의 95% 신용구간을 구하자.

집합

집합 $C \subseteq \Theta$ 이 $\pi(C \mid X) \geq 1 - \alpha$ 를 만족하면,
 C 를 θ 의 $100(1 - \alpha)\%$, $0 \leq \alpha \leq 1$
 신용집합이라고 한다.

θ 의 $100(1 - \alpha)\%$ 최고사후밀도 신용집합
 $C \subseteq \Theta$ 는 $C = \{\theta \in \Theta : \pi(\theta \mid X) \geq k\}$ 와
 같이 정의된다.
 여기서 k 는 $P(C \mid X) \geq 1 - \alpha$ 가
 되도록 정해진다

θ 의 $100(1 - \alpha)\%$ 동일꼬리 신용집합은
 $[A, B]$ 와 같이 정의되고,
 A, B 는 $\pi(\theta \leq A \mid X) = \frac{\alpha}{2}$ 와 $\pi(\theta \geq B \mid X)$
 $= \frac{\alpha}{2}$ 을 만족한다.

03 가설검정



가설검정: 문제의 구조

가설

$$\Theta = \Theta_0 \cup \Theta_1, \Theta_0 \cap \Theta_1 = \emptyset$$

$$H_0: \theta \in \Theta_0 \text{ 대 } H_1: \theta \in \Theta_1.$$

모형

$$X|\theta \sim f(X|\theta)$$

사후확률의 계산

$$\alpha_0 = \pi(\Theta_0 | X), \alpha_1 = \pi(\Theta_1 | X)$$

를 계산해보자.

사전분포

Θ 상에서의 사전분포 π 는 다음과 같이 나타낼 수 있다.

$$\pi = \pi_0 \cdot g_0(\theta) + \pi_1 \cdot g_1(\theta).$$

여기서,

1. π_0 는 H_0 의 사전확률이고, $\pi_1 \cdot H_1$ 의 사전확률이다.

$$0 \leq \pi_0, \pi_1 \leq 1, \pi_0 + \pi_1 = 1.$$

2. g_0 는 H_0 가 사실이라고 가정했을때 사전분포이고,

g_1 은 H_1 이 사실일 때 사전분포이다.

다음과 같이 π 를 이용해 나타낼 수 있다.

$$g_0(\theta) = \frac{\pi(\theta)}{\pi_0} I(\theta \in \Theta_0), g_1(\theta) = \frac{\pi(\theta)}{\pi_1} I(\theta \in \Theta_1)$$

몇 가지 용어들

□ 사전 오즈비(Prior odds ratio)

$$\frac{\pi_0}{\pi_1},$$

위에서 $\pi_0 = \pi(\Theta_0)$, $\pi_1 = \pi(\Theta_1)$.

□ 사후 오즈비(Posterior odds ratio)

$$\frac{\alpha_0}{\alpha_1} = \frac{\pi_0 \cdot m_0(X)}{\pi_1 \cdot m_1(X)} = \frac{\pi_0}{\pi_1} \times \frac{m_0(X)}{m_1(X)}$$

따라서

사후오즈비 = 사전오즈비 $\times$ 베이즈인자
와 같이 나타낼 수 있다.

□ 베이즈인자(Bayes factor)

$$B_{01} = \frac{m_0(X)}{m_1(X)}$$

$$B_{10} = \frac{m_1(X)}{m_0(X)} = \frac{1}{B_{01}}$$

단순가설 대 단순가설 (simple hypothesis)

가설

$$H_0: \theta = \theta_0 \text{ vs } H_1: \theta = \theta_1, \theta_0 \neq \theta_1$$

사전분포

$$\pi_0 = \pi\{\theta_0\}$$

$$\pi_1 = \pi\{\theta_1\}$$

사후분포

$$\alpha_0 = \pi(\{\theta_0\}|X) = \frac{\pi_0 \cdot f(X|\theta_0)}{\pi_0 \cdot f(X|\theta_0) + \pi_1 \cdot f(X|\theta_1)}$$

$$\alpha_1 = 1 - \alpha_0$$

베이즈인자

$$B_{01} = \frac{f(X|\theta_0)}{f(X|\theta_1)}$$

단순가설 대 복합가설(composite hypothesis)

가설

$$H_0: \theta = \theta_0 \text{ vs } H_1: \theta \neq \theta_0$$

사전분포

$$\pi_0 = \pi\{\theta_0\}$$

$$\pi_1 = 1 - \pi_0 = \pi\{\theta \neq \theta_0\}$$

$g_1(\theta): \Theta_1$ 상에서 사전밀도함수

$$\pi = \pi_0 \delta_{\theta_0} + \pi_1 g_1(\theta).$$

여기서 δ_{θ_0} 은 θ_0 에서 확률 1을 갖는
다락확률분포이다.

즉 $\delta_{\theta_0}(\{\theta_0\})=1$.

사후확률

$$m_1(X) = \int_{\Theta_1} f(X|\theta) \cdot g_1(\theta) d\theta.$$

$$\alpha_0 = \frac{\pi_0 \cdot f(X|\theta_0)}{\pi_0 \cdot f(X|\theta_0) + \pi_1 \cdot m_1(X)}$$

$$\alpha_1 = \frac{\pi_1 \cdot m_1(X)}{\pi_0 \cdot f(X|\theta_0) + \pi_1 \cdot m_1(X)}$$

베이즈인자

$$B_{01} = \frac{f(X|\theta_0)}{m_1(X)}$$

제프리스의 기준(Jeffreys' criteria)

$\log_{10} \frac{\pi(H_1|X)}{\pi(H_0|X)}$ $\frac{\pi(H_1|X)}{\pi(H_0|X)}$ H_1 에 대한 증거의 크기(strength of the evidence for H_1)

$0 \sim \frac{1}{2}$	$1 \sim 3.2$	간단히 언급할 가치가 없다 (<i>not worth than a bare mention</i>)
$\frac{1}{2} \sim 1$	$3.2 \sim 10$	상당하다 (<i>substantial</i>)
$1 \sim 2$	$10 \sim 100$	강하다 (<i>strong</i>)
> 2	> 100	결정적이다 (<i>Decisive</i>)

예 : 정규모형 단순귀무가설 (normal point null)

▣ 모형 $X_1, \dots, X_n | \theta \sim N(\theta, \sigma^2)$

▣ 가설 $H_0: \theta = \theta_0$ vs $H_1: \theta \neq \theta_0$

▣ 사전분포 $\pi_0 = \pi(H_0), \pi_1 = \pi(H_1)$.
 $\theta | H_1 \sim N(\theta_0, \tau^2)$. i. e. $g_1(\theta) = N(\theta_0, \tau^2)$

▣ 베이즈인자

$$B_{10} = \left(1 + \frac{n\tau^2}{\sigma^2}\right)^{-\frac{1}{2}} e^{\frac{1}{2}z^2 \frac{1}{1 + \frac{\sigma^2}{n\tau^2}}}$$

▣ 사후확률 $\alpha_0 =$

$$\left[1 + \frac{\pi_1}{\pi_0} \left(1 + \frac{n\tau^2}{\sigma^2}\right)^{-\frac{1}{2}} e^{\frac{1}{2}z^2 \frac{1}{1 + \frac{\sigma^2}{n\tau^2}}}\right]^{-1}$$

▣ 사후확률의 극한 성질

★ $|z| \uparrow \infty$ 로 가면, $B_{10} \rightarrow \infty$ 이고 $\alpha_0 \rightarrow 0$.

★ $|z| \downarrow 0$ 로 가면, $B_{10} \rightarrow \left(1 + \frac{n\tau^2}{\sigma^2}\right)^{-\frac{1}{2}}$ 이고

$$\alpha_0 \rightarrow \frac{1}{1 + \frac{\pi_1}{\pi_0} \frac{1}{\sqrt{1 + \frac{n\tau^2}{\sigma^2}}}}$$

▣ 참고

이 값은 $n, \tau^2, \sigma^2, \pi_0, \pi_1$ 이 고정되었을 때,
 z 값의 변화로 얻을 수 있는 α_0 의 최대값이다.

★ $n \uparrow \infty$ 로 가면,

$$\left(1 + \frac{\pi_1}{\pi_0} \cdot \frac{1}{\sqrt{1 + \frac{n\tau^2}{\sigma^2}}}\right)^{-1} \uparrow 1$$

★ $n \uparrow \infty$ 로 가면, $\alpha_0(z) \downarrow 0$, for $z \neq 0$.

제프리스의 역설 : 귀무가설의 사후확률과 p 값의 차이

정규모형의 가설검정 예에서 다음과 같이 정한다. Set $\tau^2 = \sigma^2$ and $\pi_0 = \pi_1 = \frac{1}{2}$

$$\alpha_0 = \left[1 + \frac{e^{\frac{1}{2}z^2} \frac{n}{n+1}}{\sqrt{1+n}} \right]^{-1}$$

Table 4.2.

z (p-value)	1	5	10	20	50	100	1000
1.645(0.1)	0.42	0.44	0.49	0.56	0.65	0.72	0.89
1.96(0.05)	0.35	0.33	0.37	0.42	0.52	0.6	0.8
2.576(0.01)	0.21	0.13	0.14	0.16	0.22	0.27	0.53
3.291(0.001)	0.086	0.026	0.024	0.026	0.034	0.045	0.124

제프리스의 파라독스(Jeffreys' paradox) 혹은 린들리의 파라독스(Lindley's paradox)

n이 매우 크면 단순귀무가설일 때 p 값은 10^{-10} 이어서 유의성검정에서는 매우 강하게 귀무가설을 기각하나, 귀무가설의 사후확률이 1에 가까워서 베이지안 가설검정에서는 귀무가설이 거의 확실하다고 결론내리는 예들이 있다. 이를 제프리스의 역설 혹은 린들리의 역설이라고 한다.

예측추론(predictive inference)

$$\theta \sim \pi(\theta)$$

$$X|\theta \sim f(X|\theta)$$

일 때, $z \sim g(z|\theta)$ 에 대해 예측하고자 한다.

이 때, x 가 주어졌을때, z 의 예측분포(predictive density)는

$$p(z|x) = \int_{\Theta_1} g(Z|\theta) \cdot \pi(\theta|X) d\theta.$$

이다.

참고문헌

1. 이궁희 외 4인. 통계학의 개념 및 제문제 9장 3,4,7절.
한국방송통신대학교출판부, 2011.
2. Berger, James O. Statistical decision theory and Bayesian analysis의
4장 3절. Springer Science & Business Media, 2013.



수고하셨습니다.

감사합니다.

