



06강

서울대학교 통계학과 이재용 교수

베이지안 통계학

다변량 정규모형



목차

01 다변량 정규모형

: 하나의 모수가 고정되었을 때

02 다변량 정규모형

: 두개의 모수를 모두 모를 때



01 다변량 정규모형: 하나의 모수가 고정되었을 때

다변량 정규모형: 공분산을 알 때 평균의 추론

□ 모형

$$X_1, \dots, X_n | \theta \stackrel{i.i.d.}{\sim} N(\theta, \Sigma), \theta \in \mathbb{R}^p,$$

$\Sigma \in \mathbb{R}^{p \times p}$ $\Sigma > 0$ 는 아는 값이고,

θ 에 대해 추론하고자 한다.

□ 사전분포

$$\theta \sim N_p(\mu_0, B_0)$$

□ 사후분포

$$\theta | X \sim N(\mu_n, B_n)$$

$$\mu_n = (B_0^{-1} + n\Sigma^{-1})^{-1}(B_0^{-1}\mu_0 + n\Sigma^{-1}\bar{x})$$

$$B_n = (B_0^{-1} + n\Sigma^{-1})^{-1}$$

□ 사후추정량

$$\hat{\theta}^B = (B_0^{-1} + n\Sigma^{-1})^{-1}(B_0^{-1}\mu_0 + n\Sigma^{-1}\bar{x})$$

□ 베이즈 추정량은 사전분포의 평균 μ_0 와 최대가능도 추정량 $\bar{x}$ 의 가중 평균이다.

□ 관측치의 개수가 커지면서, 자료가 사전분포를 압도한다.

□ $B_0 = \Sigma/k$ 놓을 때, k 는 사전분포의 개수라 해석할 수 있다.

01 다변량 정규모형: 하나의 모수가 고정되었을 때



위샤트분포와 역위샤트분포

■ 위샤트분포 (Wishart distribution)

★ 위샤트분포는 대칭이고,
양의 정부호인 랜덤행렬의 분포이다.

★ 기호 $W \sim W_p(\nu, B)$.

★ 밀도함수 $\nu > p - 1$ 일 때

$$f(W) = \frac{|W|^{\frac{(\nu-p-1)}{2}} \cdot e^{-\frac{1}{2}\text{tr}(B^{-1}W)}}{2^{\nu p/2} \cdot |B|^{\nu/2} \cdot \Gamma_p(\frac{\nu}{2})}, W > 0.$$

$\Gamma_p(\frac{\nu}{2})$ 는 다변량 감마함수로

$\Gamma_p(\frac{\nu}{2}) = \pi^{p(p-1)/4} \prod_{j=1}^p \Gamma(\frac{n}{2} - \frac{j-1}{2})$ 와 같이 정의된다.

★ 적률 $\mathbb{E}W = \nu B$.

★ $p=1$ 이면, $W(\nu, B) = \chi^2(\nu, (\nu B)^{-1})$.

■ 역위샤트분포 (Inverse – Wishart distribution)

★ 역위샤트분포는 대칭이고, 양의 정부호인 랜덤행렬의 분포이다.

★ 기호 $W \sim \text{Inv-}W_p(\nu, B)$.

★ 밀도함수 $\nu > p - 1$ 일 때

$$f(W) = \frac{|B|^{\frac{\nu}{2}}}{2^{\nu p/2} \cdot \Gamma_p(\frac{\nu}{2})} |W|^{-(\nu+p+1)/2} e^{-\frac{1}{2}\text{tr}(B \cdot W^{-1})}, W$$

★ (적률) $\mathbb{E}W = \frac{B}{\nu - p - 1}, \nu > p + 1$.

★ $W \sim W_p(\nu, B)$

$$\Leftrightarrow W^{-1} \sim \text{Inv-}W_p(\nu, B^{-1})$$

다변량 정규모형: 평균을 알 때, 공분산의 추론

□ 모형

$X_1, \dots, X_n | \theta, \overset{i.i.d.}{\sim} N(\theta, \Sigma),$
 $\theta \in \mathbb{R}^p, \Sigma \in \mathbb{R}^{p \times p}$ θ 는 아는 값일 때
 $\Sigma > 0$ 에 대해 추론하고자 한다.

□ 사전분포

$$\Sigma \sim \text{Inv} - W(v_0, B_0)$$

□ 사후분포

$$\Sigma | X \sim \text{Inv} - W(v_1, B_1)$$

$$v_n = v_0 + n$$

$$B_n = B_0 + nS.$$

$$S = \frac{1}{n} \sum_{i=1}^n (X_i - \theta)(X_i - \theta)'$$

□ 베이즈 추정량

$$\hat{\Sigma}^B = (B_0 + nS)/(v_0 + n - p - 1).$$

□ 베이즈 추정량은 사전분포의 평균

$B_0/(v_0 - p - 1)$ 과 최대가능도 추정량 S 의 가중 평균이다.

$$\hat{\Sigma}^B = \frac{v_0 - p - 1}{v_0 + n - p - 1} \frac{B_0}{v_0 - p - 1} + \frac{n}{v_0 + n - p - 1} S.$$

□ 관측치의 개수가 커지면서, 자료가 사전분포를 압도한다. 다른 모든 값들이 고정된 상태에서 n 을 무한대로 보내면

$$\lim_{n \rightarrow \infty} \hat{\Sigma}^B = S = \hat{\Sigma}^{MLE}.$$

01 다변량 정규모형: 하나의 모수가 고정되었을 때



02 다변량 정규모형: 두개의모수를 모두 모를때

다변량 정규모형과 켈레사전분포

□ 모형 $X_1, \dots, X_n | \theta, \overset{i.i.d.}{\sim} N(\theta, \Sigma), \theta \in \mathbb{R}^p, \Sigma \in \mathbb{R}^{p \times p}.$

□ 사전분포

$$\Sigma \sim \text{Inv-W}(v_0, B_0)$$

$$\theta | \Sigma \sim N(\mu_0, \Sigma/k_0).$$

$v_0 > p-1, k_0 > 0, \mu_0 \in \mathbb{R}^p, B_0 \in \mathbb{R}^{p \times p}$ 는 대칭인 양의 정부호.

□ 사후분포

$$\Sigma | x \sim \text{Inv-W}(v_n, B_n)$$

$$\theta | \Sigma, x \sim N(\mu_n, \Sigma/k_n).$$

여기서 사후분포의 모수들은 다음과 같이 결정된다.

$$v_n = v_0 + n$$

$$k_n = k_0 + n$$

$$\mu_n = \frac{1}{k_0 + n} (k_0 \mu_0 + n \bar{x})$$

$$B_n = B_0 + (n-1) \cdot S + \frac{n \cdot k_0}{n + k_0} (\mu_0 - \bar{x})(\mu_0 - \bar{x})^T$$

□ θ 의 주변 사후분포

$$\theta | x \sim t_{v_n-p+1}(\mu_n, B_n/(k_n(v_n-p+1))).$$

□ 다변량 t -분포

$$\theta \sim t_v(\mu, \Sigma), \mu \in \mathbb{R}^p, \Sigma \in \mathbb{R}^{p \times p}, \Sigma > 0$$

$$p(\theta) = \frac{\Gamma(\frac{v+p}{2})}{\Gamma(\frac{v}{2}) v^{p/2} \pi^{p/2}} |\Sigma|^{-\frac{1}{2}}$$

$$\times \left(1 + \frac{1}{v} (\theta - \mu)' \Sigma^{-1} (\theta - \mu)\right)^{-(v+p)/2}$$

$$\mathbb{E}\theta = \mu, v > 1$$

$$\text{Var}\theta = \frac{v}{v-2} \Sigma, v > 2.$$

$$S = \frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})(x_i - \bar{x})'$$



다변량 정규모형과 켈레사전분포: 사후추정량

$$\hat{\theta}^B = \mu_n$$

$$= \frac{1}{k_0 + n} (k_0 \mu_0 + n \bar{x})$$

$$\hat{\Sigma}^B = \frac{B_n}{v_n - p - 1}$$

$$= \left(B_0 + (n - 1) \cdot S + \frac{n \cdot k_0}{n + k_0} (\mu_0 - \bar{x})(\mu_0 - \bar{x})^T \right)$$

$$\times \frac{1}{v_0 + n - p - 1}.$$

모형

$$X_1, \dots, X_n | \theta, \overset{i.i.d.}{\sim} N(\theta, \Sigma), \theta \in \mathbb{R}^p, \Sigma \in \mathbb{R}^{p \times p}.$$

사후분포

$$\Sigma | x \sim \text{Inv-W}(v_n, B_n)$$

$$\theta | \Sigma, x \sim N(\mu_n, \Sigma / k_n).$$

여기서 사후분포의 모수들은 다음과 같이 결정된다.

$$v_n = v_0 + n$$

$$k_n = k_0 + n$$

$$\mu_n = \frac{1}{k_0 + n} (k_0 \mu_0 + n \bar{x})$$

$$B_n = B_0 + (n - 1) \cdot S + \frac{n \cdot k_0}{n + k_0} (\mu_0 - \bar{x})(\mu_0 - \bar{x})^T.$$

θ 의 주변 사후분포

$$\theta | x \sim t_{v_n - p + 1}(\mu_n, B_n / (k_n(v_n - p + 1))).$$

다변량 정규모형과 무정보사전분포

□ 모형

$X_1, \dots, X_n | \theta, \overset{i.i.d.}{\sim} N(\theta, \Sigma), \theta \in \mathbb{R}^p, \Sigma \in \mathbb{R}^{p \times p}.$

□ 제프리스 무정보 사전분포

$$\pi(\theta, \Sigma) \propto |\Sigma|^{-(p+1)/2}$$

□ 사후분포

$$\Sigma | x \sim \text{Inv-W}(n-1, (n-1)S)$$

$$\theta | \Sigma, x \sim N(\bar{x}, \Sigma/n).$$

□ θ 의 주변 사후분포

$$\theta | x \sim t_{n-p}(\bar{x}, \frac{n-1}{n(n-p)} S).$$

□ 베이즈 추정량

$$\hat{\theta}^B = \bar{x}$$

$$\hat{\Sigma}^B = \frac{n-1}{n-p-2} S.$$

참고문헌

- 이궁희 외 4인. 통계학의 개념 및 제문제 9장 6절.
한국방송통신대학교출판부, 2011.
- Gelman, A., Carlin, J. B., Stern, H. S., Dunson, D. B., Vehtari, A.,
& Rubin, D. B. (2013). Bayesian data analysis. Chapman and Hall/CRC.



수고하셨습니다.

감사합니다.

