

14강

서울대학교 통계학과 이재용 교수

베이지안 통계학

계층모형





목차

- 01 주의 종양 자료의 분석
- 02 작스의 수행
- 03 계층 모형



01 쥐의 종양 자료의 분석

쥐의 종양 자료

- 앤드류 겔만(Andrew Gelman)의 웹페이지에서 얻은 자료이다.
- 종양(endometrial stromal polyps)을 가진 암컷쥐들의 수가 기록되었다.
- 현재의 자료에서는 14마리의 쥐 중에 4마리의 쥐가 종양을 보였다.
- 또한 비슷한 70개의 자료가 있다.
- 목표
 - ★ 목표는 현재의 자료에서 쥐가 종양을 가질 확률 θ 를 추정하는 것이다.

자료

> rats

	n	x
1	20	0
2	20	0
3	20	0
4	20	0
5	20	0
6	20	0
7	20	0
8	19	0
...		
65	20	6
66	20	6
67	52	16
68	46	15
69	47	15
70	24	9
71	14	4


첫 번째 분석

원하는 모수 θ 에 관련된 자료는 오직 현재의 자료이므로,
과거의 모든 자료는 무시하고 현재의 자료만 이용해서 분석한다.

첫번째 분석

- 모형 $x|\theta \sim \text{Bin}(n=14, \theta)$.
- 사전분포 $\theta \sim \text{Beta}(1, 1) = \text{Uniform}(0, 1)$.
- 사후분포 $\theta|x \sim \text{Beta}(x+1, n-x+1) = \text{Beta}(5, 11)$.
- 사후분포의 평균 $\mathbb{E}(\theta|x) = \frac{5}{16} = 0.3125$
- 사후분포의 표준편차 $sd(\theta|x) = \sqrt{\frac{5*11}{16^2*17}} = 0.1124183$
- 95% 신용구간 $(0.1182411, 0.5510032)$.

첫번째 분석에서 얻은 사후분포의 밀도함수



두번째 분석


- 첫번째 분석의 문제점은 과거의 70개의 자료를 분석에 사용하지 않아서 과거의 자료에 있는 정보를 사용하지 않는다는 것이다.
- 과거의 자료를 사용하기 위해 모든 과거의 자료와 현재의 자료가 동일한 조건에서 얻어진 실험 결과인 것을 고려해서, 모든 자료를 합쳐서 분석한다.

$$x = \sum x_i (= 267) \sim \text{Bin}(\sum n_i = 1739, \theta).$$

두번째 분석

- 모형 $x|\theta \sim \text{Bin}(1739, \theta)$.
- 사전분포 $\theta \sim \text{Beta}(1, 1) = \text{Uniform}(0, 1)$.
- 사후분포 $\theta|x \sim \text{Beta}(x+1, n-x+1) = \text{Beta}(268, 1473)$.
- 사후분포의 평균 $\mathbb{E}(\theta|x) = \frac{268}{1741} = 0.1539345$
- 사후분포의 표준편차 $sd(\theta|x) = \sqrt{\frac{268*1473}{1741^2*1742}} = 7.476388e-05$
- 95% 신용구간 (0.1373692, 0.1712529).

두번째 분석에서 얻은 사후분포의 밀도함수



$\theta_1 = \dots = \theta_{71}$ 이라고 믿을 수 있는가?

- 두번째 분석의 문제점은 모든 실험이 엄밀하게 동일한 조건에서 수행되었다고 믿을 수 없는데도 불구하고 71개의 이항실험의 모든 θ_i 들이 같은 값을 갖는다고 가정했다는 데 있다.

$$x_i \sim \text{Bin}(n_i, \theta_i), i = 1, \dots, 71.$$

$\theta_1 = \dots = \theta_{71}$ 이라고 믿을 수 있는가?

이를 알아보기 위해 다음을 정의하자.





$$\bar{\theta} = \frac{\sum X_i}{\sum n_i} = 0.1535365$$

$$\hat{\theta}_i = \frac{x_i + 0.5}{n_i + 1}$$

$$z_i = \frac{\hat{\theta}_i - \bar{\theta}}{\sqrt{\hat{\theta}_i(1 - \hat{\theta}_i)/n_i}}.$$

만약 모든 θ_i 가 같다면 z_i 는 근사적으로 $N(0, 1)$ 를 따를 것이다.
다음은 z_i 들의 히스토그램과 정규 Q-Q 그림이다.

¹ Instead of x_i / n_i , we use this estimator because there are many 0s.

Histogram of $\hat{\phi}$ Histogram of z  z q-q plot of $z[y>0]$ 

01 쥐의 종양 자료의 분석

□ 위의 히스토그램과 정규 Q-Q 그림을 보면 z_i 들은 $N(0, 1)$ 에서 발생되었다고 보기 힘들다.

□ 주요한 이유는 많은 0 때문이다.

$x_i = 0$ 인 자료를 제외한 x_i 들의 정규 Q-Q 그림은 직선에 가깝다.

하지만 많은 0을 무시할 수는 없다.

□ 첫번째와 두번째 분석 모두 만족스럽지 못하다.

세 번째 분석

과거 70개의 자료를 이용하여 정보를 가진(informative) 사전분포를 구축한다. 70개의 θ_i 가 정확히 동일한 값은 갖지 않지만 비슷하다는 가정은 매우 합리적이다. 다음을 가정한다.

$$\theta_i \sim \text{Beta}(\alpha, \beta), i = 1, \dots, 71,$$

위의 가정하에서 α 와 β 를 추정한다.

01 쥐의 종양 자료의 분석

과거 70개의 $\hat{\theta}_i$ 들의 표본평균과 표본표준편차는
각각 0.1524775, 0.009511018이다.² 아래의 식을 풀어서

$$\frac{\alpha}{\alpha+\beta} = 0.1524$$

$$\frac{\alpha\beta}{(\alpha+\beta)^2(\alpha+\beta+1)} = 0.009511^2,$$

다음의 값들을 얻는다.

$$\alpha = 1.919$$

$$\beta = 10.66794.$$

² 이를 위해 추정량 $\hat{\theta}_i = (y_i + 0.5)/(n_i + 1)$ 이 사용되었다.

01 쥐의 종양 자료의 분석

□ 모형 $x|\theta \sim \text{Bin}(n=14, \theta)$.

□ 사전분포 $\theta \sim \text{Beta}(1.919, 10.66794)$.


□ 사후분포 $\theta|x \sim \text{Beta}(5.919, 20.66794)$.

★ 사후분포의 평균 $\mathbb{E}(\theta|x) = 0.2226281$.

★ 사후분포의 표준편차 $sd(\theta|x) = 0.07920501$

★ 95% 신용구간 $(0.0892141, 0.3953855)$.

세 번째 분석에서 얻은 사후분포의 밀도함수



세번째 분석에서 얻은 사후분포의 밀도함수

- 명백하게 세번째 분석은 첫번째와 두번째 분석보다 훨씬 합리적이다. 하지만 세번째 분석도 몇 가지 문제점을 가지고 있다.
- 만약 우리가 θ_i , $i = 1, 2, \dots, 70$ 에 대해서도 동일한 분석을 원한다면, 각각의 θ_i 에 대해 동일한 분석을 다시 해야한다.
- 분석에서 초모수(Hyperparameter) α 와 β 를 추정하여 사용하였는데, 마치 이들이 고정된 값인 것처럼 사용하였다. 즉, 초모수의 추정에서 유래하는 불확실성을 무시하였다.
- 초모수 α 와 β 를 추정해야 하기 때문에, α 와 β 에 사전분포를 거는 것이 자연스럽다.

세 번째 분석에서 얻은 사후분포의 밀도함수

- 우리는 주어진 모든 자료를 사용하고 싶고 또한 θ_i 들이 다르다는 것을 인정한다.
- 이를 위해서, θ_i 들은 하나의 확률분포에서 발생하였고
이 분포는 비슷한 실험에서 발생하는 모든 가능한 θ_i 들의 분포라고 가정한다.

$$\theta_i \stackrel{i.i.d.}{\sim} \pi(\cdot). \quad (1)$$

- 위의 가정은 교환가능성(Exchangeability)에 근거했다고 볼 수도 있다.
교환가능성은 자료를 보기 전에 θ_i 들 간에
서로 구별하는 어떤 정보도 없을 때 타당한 가정이다.

계층모형(Hierarchical Model)

□ 모형

x_i 에 관한 모형은 전과 동일하다.

$$x_i | \theta_i \sim \text{Bin}(n_i, \theta_i), i=1, \dots, 71$$

□ 사전분포

θ_i 는 한 개의 분포에서 발생하였고,
이 분포는 모든 가능한 θ_i 들의 분포를 나타낸다.

$$\theta_i \sim \text{Beta}(\alpha, \beta), i=1, \dots, 71.$$

□ 초사전분포

초모수 α 와 β 를 모르므로, 이들에 사전분포를 건다.

$$\alpha \sim \text{Gamma}(a_\alpha, b_\alpha) \quad \beta \sim \text{Gamma}(a_\beta, b_\beta).$$

초모수의 선택

□ 다음과 같이 놓는다.

$$\frac{a_{\alpha}}{b_{\alpha}}=1$$

$$\frac{a_{\alpha}}{b_{\alpha}^2}=10^3$$

여기서 중요한 것은 초모수의 사전분포의 분산을 크게 놓는 것이다.

□ 위의 방정식을 풀면 다음을 얻는다.

$$a_{\alpha} = b_{\alpha} = 10^{-3}.$$

마찬가지로, 다음을 얻는다.

$$a_{\beta} = b_{\beta} = 10^{-3}.$$

최종 모형

□ Model

$$x_i | \theta \sim \text{Bin}(n_i, \theta_i), i = 1, \dots, 71.$$

□ Prior

$$\theta_i \sim \text{Beta}(\alpha, \beta), i = 1, \dots, 71.$$

□ Hyperprior

$$\alpha \sim \text{Gamma}(10^{-3}, 10^{-3}) \text{ and} \\ \beta \sim \text{Gamma}(10^{-3}, 10^{-3}).$$

02 작스의 수행

최종 모형

```
library(rjags)
model = "
model {
  for (i in 1:N) {
    x[i] ~ dbin(theta[i], n[i])
    theta[i] ~ dbeta(alpha, beta)
  }
  alpha ~ dgamma(1E-3, 1E-3)
  beta ~ dgamma(1E-3, 1E-3)
}
"
```

```
jags <- jags.model(textConnection(model), data = list('x'=rats$x,'n'=rats$n,
'N'=length(rats$x)), n.chains = 1, n.adapt = 1000)
post <- coda.samples(jags, c("theta", "alpha", "beta"), 5000)
```

```
summary(post.sm)
par(mfrow=c(2,2))
traceplot(post.sm)
autocorr.plot(post.sm)
par(mfrow=c(1,1))
```

03 계층 모형

계층모형 적용 자료 구조: 내포 자료와 집락표집설계

- ❑ 예: 강의 방법 효과 조사에서 학교를 랜덤하게 선택한 후에, 선택된 학교에서 다시 학생들을 랜덤하게 선택하여 조사.
 - ❑ 내포 자료(nested data)에서는 하나의 층이 다른 층의 꼭 한 개의 값에만 나타난다. 즉 한 명의 학생이 하나의 학교에게만 나타난다. 한 명의 학생이 여러 학교에 나타나면 이를 교차 자료 구조(crossed data structure)라고 한다.
 - ❑ 이러한 표집방법을 집락표집설계(cluster sampling design)라고 한다.
 - ❑ 학교를 무시하고 1원배치 분산분석을 사용하면 중요한 인자를 무시하게 된다.
-
- ★ 예. 직장 만족도 조사. 큰 회사 안에 여러 개의 부서가 있고 부서 안의 직원을 조사.
 - ★ 예. 진료 만족도 조사. 심리치료사가 여러 명의 환자를 담당하고 있다. 환자는 여러 번의 세션을 갖는다. 세 개의 층이 있다. 치료사, 환자, 세션. 세션 후에 환자에게 조사.

계층모형의 일관성 쌍둥이들

- 경험적 베이즈 모형(empirical Bayes method)
- 다층 모형(multilevel model)

참고문헌

1. Hoff, P. D. (2009). A first course in Bayesian statistical methods의 9장. Springer Science & Business Media.
2. Lunn, D., Jackson, C., Best, N., Spiegelhalter, D., & Thomas, A. (2012). The BUGS book: A practical introduction to Bayesian analysis. Chapman and Hall/CRC.



수고하셨습니다.

—
감사합니다.

