

1. 이진 분류를 위한 LDA 방법론을 유도하는 과정에 관한 다음 질문에 답하시오.

1-1. Between-class scatter matrix  $S_B$  가 왜  $(m_2 - m_1)(m_2 - m_1)^T$ 로 되는지 설명하시오.

- 선형판별분석(LDA)는 두 개의 클래스를 2차원 공간에서 1차원으로 투영시켜 각 클래스를 가장 잘 구분되도록 하는 방법이다.

데이터  $\vec{x}$ 를 1차원 속  $\vec{w}$  방향으로 사영해서  $y = \vec{w}^T \vec{x}$ 로 변환한다.

- 이를 위해 두 클래스의 투영된 평균값  $m_1, m_2$ 가 최대한 멀어지도록 하고  
두 클래스 내부의 변동성은 여한 값  $N_1 S_1^2 + N_2 S_2^2$ 은 작아지도록 해야한다.

- 하나의 성능지표로 표현하면  $PI_{LDA}(\vec{w}) = \frac{(m_2 - m_1)^2}{N_1 S_1^2 + N_2 S_2^2}$  이 된다.

- 성능지표의 분자 부분을 보면

$$(m_2 - m_1)^2 = (\vec{w}^T (\vec{m}_2 - \vec{m}_1))^2 = \vec{w}^T (\vec{m}_2 - \vec{m}_1) (\vec{m}_2 - \vec{m}_1)^T \vec{w} \quad \text{인테}$$

여기서 클래스 간 산포 행렬  $S_B = (\vec{m}_2 - \vec{m}_1)(\vec{m}_2 - \vec{m}_1)^T$ 로 정의하면  
분자 부분을  $\vec{w}^T S_B \vec{w}$ 로 표현할 수 있다.

1-2. Within-class scatter matrix  $S_W$ 를 유도하시오.

- 성능지표의 분모 부분을 보면

$$\begin{aligned} N_1 S_1^2 + N_2 S_2^2 &= \sum_{i=1}^2 \sum_{n \in C_i} (y_n - m_i)^2 \\ &= \sum_{i=1}^2 \sum_{n \in C_i} (\vec{w}^T \vec{x}_n - \vec{w}^T \vec{m}_i)^2 \\ &= \sum_{i=1}^2 \sum_{n \in C_i} \vec{w}^T (\vec{x}_n - \vec{m}_i) (\vec{x}_n - \vec{m}_i)^T \vec{w} \quad \text{이다.} \end{aligned}$$

- 여기서 클래스 내 산포 행렬  $S_W = \sum_{i=1}^2 \sum_{n \in C_i} (\vec{x}_n - \vec{m}_i)(\vec{x}_n - \vec{m}_i)^T$ 로 정의하면  
분모 부분은  $\vec{w}^T S_W \vec{w}$ 로 표현할 수 있다.

1-3. LDA의 성능지표(특정함수)에 관하여 기술하고, 이러한 성능지표가 왜 효과적인 이진분류 결과를 제공할 수 있는지 직관적으로 설명하시오.

$$\text{성능지표 } PI_{LDA} = \frac{(m_2 - m_1)^2}{N_1 S_1^2 + N_2 S_2^2} = \frac{\vec{w}^T S_B \vec{w}}{\vec{w}^T S_W \vec{w}}$$

∴ 성능지표  $PI_{LDA}$ 의 값은  $\vec{w}$ 의 크기는 무관하고 방향만 의미를 갖는다.

성능지표의 분자는 투영된 두 클래스의 평균이 멀리 떨어질수록 커지고,

분모는 투영된 두 클래스가 각각 모여있을수록 작아진다.

즉, 성능지표가 클수록 투영된 두 클래스가 서로 멀리 떨어지면서 각자 뭉쳐있게 된다.

단순히 평균 거리만 최대화하거나 각 클래스의 분산만 최소화하는 것보다 두 조건이 균형을 동시에 최적화하기 때문에 효과적인 이진분류가 가능하다.

2. 생성적 접근 방식 (Generative approach)으로 이진 분류 문제를 다룰 때,  $p(C_i|x)$ 를 시그모이드 함수 형태로 표현할 수 있도록 하는 조건을 기술하고, 시그모이드 함수 형태 결과를 유도하시오.

$p(C_i|x)$ 를 시그모이드 함수 형태로 표현하려면

두 클래스의 클래스-조건부 밀도가 같은 공분산 행렬  $\Sigma$ 를 공유하는 다변량 정규분포를 따라야 함

∴ 공분산이 다르면  $\vec{x}$ 의 이차항이 생겨서 시그모이드 형태가 나오지 않는다.

$$p(C_i|x) = \frac{p(x|C_i)p(C_i)}{p(x|C_1)p(C_1) + p(x|C_0)p(C_0)} = \frac{1}{1 + \frac{p(x|C_0)p(C_0)}{p(x|C_1)p(C_1)}}$$

$$\text{여기서 } \alpha = \ln \frac{p(x|C_1)p(C_1)}{p(x|C_0)p(C_0)} \text{ 이라 하면 } p(C_1|x) = \frac{1}{1 + e^{-\alpha}} \text{ 이 되며.}$$

두 클래스의 공분산이 동일하면  $\vec{x}$ 의 이차항  $\vec{x}^T \Sigma^{-1} \vec{x}$ 가 서로 취소되어  $\alpha = \vec{w}^T \vec{x} + w_0$ 가 된다 (스칼라 값)

따라서  $p(C_1|x) = \frac{1}{1 + e^{-\alpha}}$  형태의 시그모이드 함수가 된다.

4. SVR 을 위한  $\epsilon$ -insensitive 손실함수를 정의하고, 이것의 작용 방식과 의미에 관하여 직관적으로 논하시오.

$\epsilon$ -insensitive 손실함수는 다음과 같다.

$$|t_n - y(x_n)|_{\epsilon} = \max(|t_n - y(x_n)| - \epsilon, 0)$$

- 예측값  $y(x_n)$  이  $\epsilon$ -tube 안에 있으면 0  
 $\epsilon$ -tube 범위를 벗어나면 초과분만큼 손실로 계산.
- $\epsilon$ -insensitive 손실함수는 예측값과 실제 타겟 사이의 차이가 작은 경우에는 패널티를 주지 않음 ( $\epsilon$ -tube 구간)
- $\epsilon$ -tube 밖으로 벗어나면 손실이 발생
- 지나친 과적합을 방지하는 효과.

5. 트랜스포머 각 구성 요소의 역할

- Encoder : 입력된 문장의 전체적인 의미와 문맥을 깊이있게 파악
- Multi-head Attention : 입력된 문장 안에서 단어들이 어떤 연관성을 갖는지 파악
- Add & Norm : 이전 층의 원본 정보를 더해 손실을 막고 (Add)  
값들이 한쪽으로 치우치지 않게 정규화 (Norm)
- Feed Forward : 특징들을 추출하고 학습하여 다음 층으로 전달
- Decoder : 인코더가 파악한 정보를 바탕으로 한 단어씩 차례로 생성
- Embedding : 단어를 컴퓨터가 연산할 수 있는 숫자로 변환
- Positional Encoding : 각 단어의 위치 정보를 수학적으로 계산하여 더해 줌