

05강

머신러닝

다변량 분포와 지수족 분포

통계·데이터과학과 박준희



✧ 학습목차

- 1 다변량정규분포
- 2 다항분포
- 3 지수족 분포



1

다변량 정규분포



1

다변량 정규분포

● 다변량 정규분포(Multivariate normal distribution)

- 정규분포를 다차원으로 확장한 형태

- pdf : $f(\mathbf{x}) = \frac{1}{(2\pi)^{d/2} |\Sigma|^{1/2}} e^{\left(-\frac{1}{2}(\mathbf{x} - \boldsymbol{\mu})^T \Sigma^{-1} (\mathbf{x} - \boldsymbol{\mu})\right)}$

다변량 정규분포의 특징

- $\boldsymbol{\mu}$: d 차원의 평균 벡터 / $E[\mathbf{X}] = \boldsymbol{\mu}$
- Σ : $d \times d$ 공분산 행렬 / $\text{Var}[\mathbf{X}] = \Sigma$
- $\mathbf{x}$: d 차원의 벡터
- 주변분포와 조건부분포 역시 정규분포를 따름

1

다변량 정규분포


● 다변량 정규분포 실습

```
[38]: # Sampling from a Multivariate Normal distribution
mu = np.array([0, 0])
cov = np.array([[1, 0.8], [0.8, 1]])
mvn_rv = multivariate_normal(mean=mu, cov=cov)
samples = mvn_rv.rvs(size=1000, random_state=1)
# Plotting Samples
plt.figure(figsize=(8, 6))
plt.scatter(samples[:, 0], samples[:, 1], alpha=0.5)
plt.title("Samples from Multivariate Gaussian")
plt.xlabel("$x_1$")
plt.ylabel("$x_2$")
plt.grid()
plt.show()
```

1

다변량 정규분포

● 다변량 정규분포 실습



출처:파이썬 프로그램 실습내용 중

1

다변량 정규분포

● 다변량 정규분포 실습

```
[44]: # PDF: 3D graph
      from mpl_toolkits.mplot3d import Axes3D

      x1 = np.linspace(-3, 3, 500)
      x2 = np.linspace(-3, 3, 500)
      X1, X2 = np.meshgrid(x1, x2)
      pos = np.dstack((X1, X2))
      Z = mvn_rv.pdf(pos)


      fig = plt.figure(figsize=(8, 6))
      ax = fig.add_subplot(1, 1, 1, projection='3d')
      ax.plot_surface(X1, X2, Z, cmap='viridis', linewidth=0, antialiased=False)
      ax.set_xlabel('$x_1$')
      ax.set_ylabel('$x_2$')
      ax.set_zlabel('Density')
      ax.set_title('PDF of a bivariate normal distribution')
      plt.show()
```

1

다변량 정규분포

● 다변량 정규분포 실습

PDF of a bivariate normal distribution



출처:파이썬 프로그램 실습내용 중

1

다변량 정규분포


● 다변량 정규분포 실습

```
[45]: # PDF: Contour
plt.figure(figsize=(8, 6))
plt.contour(X1, X2, Z, levels=5, colors='blue')
plt.xlabel('$x_1$')
plt.ylabel('$x_2$')
plt.xlim(-3.3, 3.3)
plt.ylim(-3.3, 3.3)
plt.title('Contour plot')
plt.grid()
plt.show()
```

1

다변량 정규분포

● 다변량 정규분포 실습



출처:파이썬 프로그램 실습내용 중

1

다변량 정규분포

● 고유값 분해(Eigenvalue Decomposition)

- 정방행렬을 고유값과 고유벡터들로 분해
- 행렬 C 가 대칭이고 양정행렬(positive-definite)일때,

$$C = U\Lambda U^T.$$

- U : 정규직교(orthonormal) 행렬 ($U^T U = I$).
열벡터들은 C 의 고유벡터들.
- Λ : 대각(diagonal) 행렬 ($\text{diag}(\lambda_1, \lambda_2, \dots, \lambda_n)$).
 $\lambda_1, \lambda_2, \dots, \lambda_n$ 은 C 의 고유값들.
- $U\Lambda U^T$: 고유벡터들의 가중합으로 표현 가능

● 고유값 분해(Eigenvalue Decomposition)

```
[11]: # Illustrative Code: Eigenvalue Decomposition
C = np.array([[4, 2], [2, 3]])
eigenvalues, eigenvectors = np.linalg.eigh(C)
# Reconstruction
reconstructed_C = eigenvectors @ np.diag(eigenvalues) @ eigenvectors.T
# Print results
print("Original Matrix C:")
print(C)
print("Eigenvalues ( $\lambda$ ):")
print(eigenvalues)
print("Eigenvectors (U):")
print(eigenvectors)
print("Reconstructed Matrix ( $U\Lambda U^T$ ):")
print(reconstructed_C)
```

1

다변량 정규분포

● 고유값 분해(Eigenvalue Decomposition)

Original Matrix C:

```
[[4 2]  
 [2 3]]
```

Eigenvalues (λ):

```
[1.43844719 5.56155281]
```

Eigenvectors (U):

```
[[ 0.61541221 -0.78820544]  
 [-0.78820544 -0.61541221]]
```

Reconstructed Matrix ($U\Lambda U^T$):

```
[[4. 2.]  
 [2. 3.]]
```

1

다변량 정규분포

● Location-Dispersion Ellipsoid

- 다변량 정규분포의 기하학적 표현 (위치 & 산포)
- 고유값은 타원 축의 길이를, 고유벡터는 축의 방향을 나타냄

```
[23]: # Eigen decomposition
      eigenval, eigenvect = np.linalg.eigh(cov)
      order = eigenval.argsort()[::-1] # descending order
      eigenval, eigenvect = eigenval[order], eigenvect[:, order]
      print(eigenval)
      print(eigenvect)

[1.8  0.2]
[[ 0.70710678 -0.70710678]
 [ 0.70710678  0.70710678]]
```

● Location-Dispersion Ellipsoid

```
[32]: from matplotlib.patches import Ellipse
      # Ellipse parameters
      width = 4 * np.sqrt(eigenval[0]) # Major axis (4 SD)
      height = 4 * np.sqrt(eigenval[1]) # Minor axis (4 SD)
      angle = np.degrees(np.arctan2(eigenvec[1,0],eigenvec[0,0]))

      # Plotting
      fig, ax = plt.subplots(figsize=(8, 6))
      ellipse = Ellipse(xy=mu, width=width, height=height, angle=angle,
                        edgecolor='blue', facecolor='none', linewidth=2)
      ax.add_patch(ellipse)
```

1

다변량 정규분포

● Location-Dispersion Ellipsoid



```
for i in range(len(eigenval)):
    vector = eigenvec[:, i] * 2 * np.sqrt(eigenval[i])
    ax.quiver(*mu, *vector, angles='xy', scale_units='xy', scale=1, color='red', alpha=0.7)

# Set axes limits and labels
ax.set_xlim(-3.3, 3.3)
ax.set_ylim(-3.3, 3.3)
ax.set_title("Location-Dispersion Ellipsoid")
ax.set_xlabel("$x_1$")
ax.set_ylabel("$x_2$")
plt.grid()
plt.show()
```


1

다변량 정규분포

Location-Dispersion Ellipsoid



1

다변량 정규분포

● 다변량 정규분포의 주변분포(Marginal distribution)

- 다변량정규분포를 따르는 랜덤벡터 $X \sim N(\mu, \Sigma)$

$$X = \begin{bmatrix} X_1 \\ X_2 \end{bmatrix}, \quad \mu = \begin{bmatrix} \mu_1 \\ \mu_2 \end{bmatrix}, \quad \Sigma = \begin{bmatrix} \Sigma_{11} & \Sigma_{12} \\ \Sigma_{21} & \Sigma_{22} \end{bmatrix},$$

- X_1, X_2 의 주변분포

$$X_1 \sim N(\mu_1, \Sigma_{11}),$$

$$X_2 \sim N(\mu_2, \Sigma_{22}).$$

1

다변량 정규분포

● 다변량 정규분포의 조건부분포(Conditional distribution)

- X_2 가 주어졌을 때 X_1 의 조건부분포

$$X_1|X_2 \sim N(\mu_{1|2}, \Sigma_{1|2}),$$

where:

$$\mu_{1|2} = \mu_1 + \Sigma_{12}\Sigma_{22}^{-1}(X_2 - \mu_2),$$


$$\Sigma_{1|2} = \Sigma_{11} - \Sigma_{12}\Sigma_{22}^{-1}\Sigma_{21}.$$

1

다변량 정규분포

● 다변량 정규분포의 최대 가능도 추정(MLE)

- 평균: $\hat{\mu} = \frac{1}{n} \sum_{i=1}^n x_i$ / 공분산: $\hat{\Sigma} = \frac{1}{n} \sum_{i=1}^n (x_i - \hat{\mu})(x_i - \hat{\mu})^T$



출처:파이썬 프로그램 실습내용 중

2

다항분포



2 다항분포

● 다항분포(Multinomial distribution)

- 이항분포를 다차원으로 확장한 형태
- pmf:

$$P(\mathbf{X} = \mathbf{x}) = \frac{N!}{x_1!x_2!\dots x_k!} \prod_{i=1}^k p_i^{x_i}$$

- N : 총 시행 횟수
- p_i : i 번째 결과의 확률 ($\sum p_i = 1$)
- x_i : i 번째 결과의 횟수 ($\sum x_i = N$)

2 다항분포

● 다항분포의 기대값, 분산, 공분산

$\mathbf{X} = [X_1, X_2, \dots, X_k]^T \sim \text{Multi}(p_1, p_2, \dots, p_k)$ 일 때,

- 랜덤변수 X_i 의 기대값:

$$E[X_i] = Np_i.$$

- 랜덤변수 X_i 의 분산:

$$\text{Var}(X_i) = Np_i(1 - p_i).$$

- 랜덤변수 $X_i, X_j (i \neq j)$ 의 공분산:

$$\text{Cov}(X_i, X_j) = -Np_i p_j.$$

2 다항분포

● 다항분포의 기대값, 분산, 공분산

$$\Sigma = \begin{bmatrix} \text{Var}(X_1) & \text{Cov}(X_1, X_2) & \cdots & \text{Cov}(X_1, X_k) \\ \text{Cov}(X_2, X_1) & \text{Var}(X_2) & \cdots & \text{Cov}(X_2, X_k) \\ \vdots & \vdots & \ddots & \vdots \\ \text{Cov}(X_k, X_1) & \text{Cov}(X_k, X_2) & \cdots & \text{Var}(X_k) \end{bmatrix},$$

2 다항분포

● 다항분포 예제

- 주사위를 6번 던진다면?

```
[43]: # Illustrative Code: Multinomial Sampling
      from scipy.stats import multinomial
      # Parameters
      N = 6 # Number of trials
      probs = [1/6]*6
      # 6번씩 던진 샘플을 5개 얻었을 때
      outcomes = multinomial.rvs(n=N, p=probs,
                                size=5, random_state=1)
      print("Multinomial samples:\n", outcomes)
```

2 다항분포

● 다항분포 예제

- 주사위를 6번 던진다면? - 표본

Multinomial samples:

`[[1 1 0 1 1 2]`

`[0 0 1 1 2 2]`

`[1 1 0 2 0 2]`

`[1 1 1 0 1 2]`

`[2 2 0 1 1 0]]`

2 다항분포

● 다항분포 예제

- 주사위를 6번 던진다면? - 표본 평균, 표본 공분산

```
[45]: # 표본 평균
      sample_mean = np.mean(outcomes, axis=0)
      # 표본 공분산
      sample_cov = np.cov(outcomes, rowvar=False)
      print(sample_mean)
      print(sample_cov)
```

```
[1.  1.  0.4 1.  1.  1.6]
[[ 0.5  0.5 -0.25  0.  -0.25 -0.5 ]
 [ 0.5  0.5 -0.25  0.  -0.25 -0.5 ]
 [-0.25 -0.25  0.3 -0.25  0.25  0.2 ]
 [ 0.    0.   -0.25  0.5 -0.25  0.  ]
 [-0.25 -0.25  0.25 -0.25  0.5  0.  ]
 [-0.5  -0.5  0.2  0.    0.    0.8 ]]
```

2 다항분포

● 다항분포 예제

- 주사위를 6번 던졌을 때, $[1, 1, 1, 1, 1, 1]$ 이 나올 확률?
- 주사위를 6번 던졌을 때, $[2, 2, 2, 0, 0, 0]$ 이 나올 확률?

```
[28]: # 특정 결과의 확률 계산
x1 = [1, 1, 1, 1, 1, 1]
x2 = [2, 2, 2, 0, 0, 0]
prob1 = multinomial.pmf(x1, n=N, p=probs)
prob2 = multinomial.pmf(x2, n=N, p=probs)
print(prob1)
print(prob2)

0.01543209876543212
0.0019290123456790144
```

3

지수족 분포



3 지수족 분포

● 지수족 분포(Exponential family)

$$f(x|\eta) = h(x) \exp(\eta^T u(x) - A(\eta)),$$

- η : 자연모수(natural parameter) 벡터
- $u(x)$: 충분통계량(sufficient statistics) 벡터
- $A(\eta)$: 로그분할함수(log-partition function)
- $h(x)$: 기저 함수(base function)

3 지수족 분포

● 지수족 분포의 예: 정규분포

$$f(x|\mu, \sigma^2) = \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left(-\frac{1}{2\sigma^2}(x - \mu)^2\right).$$

지수족 분포 형태로 다시 쓰면:

$$f(x|\eta) = \exp(\eta_1 x + \eta_2 x^2 - A(\eta)),$$

- 충분통계량: $u(x) = [x, x^2]^T$
- 자연모수: $\eta = \left[\frac{\mu}{\sigma^2}, -\frac{1}{2\sigma^2}\right]^T$
- 로그분할함수: $A(\eta) = \frac{\mu^2}{2\sigma^2} + \frac{1}{2}\log(2\pi\sigma^2) = -\frac{\eta_1^2}{4\eta_2} + \frac{1}{2}\log\left(-\frac{\pi}{\eta_2}\right)$
- 기저함수: $h(x) = 1$

3 지수족 분포

● 지수족 분포의 예 : 베르누이분포

$$P(X = x) = \mu^x (1 - \mu)^{1-x}.$$

지수족 분포 형태로 다시 쓰면:

$$P(X = x) = \exp \left(x \log \left(\frac{\mu}{1 - \mu} \right) + \log(1 - \mu) \right).$$

- 충분통계량: $u(x) = x$
- 자연모수: $\eta = \log \left(\frac{\mu}{1 - \mu} \right)$
- 로그분할함수: $A(\eta) = -\log(1 - \mu) = \log(1 + e^\eta)$
- 기저함수: $h(x) = 1$

3 지수족 분포

● 지수족 분포의 예: 포아송분포

$$P(X = x) = \frac{\lambda^x e^{-\lambda}}{x!}.$$

지수족 분포 형태로 다시 쓰면:

$$P(X = x) = \exp(x \log(\lambda) - \lambda - \log(x!)).$$

- 충분통계량: $u(x) = x$
- 자연모수: $\eta = \log(\lambda)$
- 로그분할함수: $A(\eta) = \lambda = e^\eta$
- 기저함수: $h(x) = \frac{1}{x!}$

3 지수족 분포

● 지수족 분포가 아닌 예 : 균등분포

$$f(x|a, b) = \begin{cases} \frac{1}{b-a} & \text{if } a \leq x \leq b, \\ 0 & \text{otherwise.} \end{cases}$$

$$P(X = x) = \frac{1}{n}, \quad x \in \{a, a+1, \dots, b\}.$$

3

지수족 분포

- 지수족 분포가 아닌 예 : 이항분포 (N 을 모수로 볼 경우)

$$P(X = x) = \binom{N}{x} p^x (1 - p)^{N-x}.$$

★ 정리하기

■ 다변량정규분포

정규분포의 다차원 확장, 고유값 분해, 조건부 분포, 주변 분포
다변량정규분포의 최대 가능도 추정

■ 다항분포

이항분포를 셋 이상의 결과로 확장, 다항분포의 공분산 구조

■ 지수족 분포

자연모수, 충분통계량, 로그분할함수, 기저함수
정규분포, 베르누이분포, 포아송분포

06 강

다음시간안내

차원 축소 기법

