주거용 건물의 에너지 효율성 분석을 위해 베이지안 접근법을 사용한 선형회귀 모델

Linear regression model using bayesian approach for energy performance of residential building

Syarifah Diana Permai, Heruna Tanty

Abstract

저자들은 통계학에는 빈도주의와 베이지안의 두 가지 관점이 있다고 한다. 두 접근법의 차이는 모수를 바라보는 관점의 차이에서 발생하는데, 베이지안은 모수를 확률변수로 바라본다고 설명한다. 반대로 생각하면 빈도주의자들은 모수를 하나의 정해진 값으로 본다는 의미이다.

가장 흔히 사용하는 통계적 모델링은 선형회귀모델이며, 빈도주의에서 사용하는 최소제곱법과 최대우도추정방법보다 베이지안이 더 나은 결과를 보여주었다는 점을 설명한다.

1. 서론

선형회귀 분석은 횡단면 분석에 가장 흔하게 사용되는 통계적 모델링 방법이다. 회귀모델에서는 종속변수가 독립변수가 있는데, 종속변수는 하나의 수치형 데이터여야 하고, 독립변수는 하나 이상의 범주형, 수치형 데이터일 수 있다. 독립변수가 하나일 경우 단순선형회귀분석이라고 하고, 여러 개일 경우 다중선형회귀분석이라고 한다. 또한, 독립변수의 척도가 범주형일 경우 더미회귀분석이라 부른다.

선형회귀분석의 목적은 세 가지이다. 첫째, 독립변수와 종속변수 사이의 관계를 알기 위해 회귀모델을 만든다. 둘째, 독립변수의 영향이 종속변수에 영향을 주는지 테스트한다. 셋째, 결정된 독립변수에 기초하여 종속변수의 값을 예측한다.

회귀모델은 회귀모델 모수를 변수를 추정하여 완성된다. 그러면 각 독립변수에 대한 회귀계수가 도출된다. 회귀모델 모수를 추정하는 데 연구자들이 가장 자주 사용하는 방법은 최소제곱법과 최대우도추정법 같은 빈도주의적(고전적) 방법이다.

최소제곱법은 오차의 제곱합을 최소화하여 회귀모델의 매개변수를 추정하는 방법이다. 최대우도추정법은 데이터의 확률밀도함수를 최대화하는 방법이다. 두 방법을 사용할 때 회귀모델 결과는 오차의 독립성, 동일분포성, 정규분포성 등을 가정한다.

이 두 방법 외에도 베이지안 접근법을 사용하여 회귀모델의 모수를 추정할 수 있다. 베이지안은 모수를 확률변수로 보기 때문에 그 값이 단일값이 아닌 분포로 표현된다.

최소제곱법을 사용하는 선형회귀에는 일부 가정이 존재하는데, 이 가정이 만족되지 않으면 문제가 발생할 수 있다. 특히 이상치가 존재하면 잔차의 독립성 가정을 만족하지 못할 수 있다. 반면 베이지안 선형회귀는 이상치를 수용할 수 있다.

이번 연구는 공기 상태를 유지하기 위해 필요한 냉방 장비를 결정하기 위해 에너지 효율성 데이터셋을 사용한다. 반복가중최소제곱법과 랜덤포레스트를 사용하여 주택건물의 에너지 성능을 분석했다. 연구목표는 다음과 같다. 첫째, 최소제곱법을 사용하여 선형회귀모델을 만든다. 둘째, 베이지안 접근법을 사용하여 선형회귀모델을 만든다. 셋째, 최적인 선형모델을 찾는다.

2. 선형회귀모델(빈도주의)

선형성에는 모수에 대한 선형성과 변수에 대한 선형성이 있다. 모델이 모수에 대해 선형이면 선형 모델이라고 한다. 따라서 변수에 대해 비선형이더라도 모수에 대해 선형이면 선형 모델로 간주된다.

여러 개의 독립변수가 있을 때 다중 선형 회귀 모델은 종속변수와 두 개 이상의 독립변수 간의 관계를 평가하는 데 사용된다. 선형 회귀 모델을 수행하기 전에 각 독립변수와 종속변수 간에 상관 관계가 있는지, 그리고 종속변수와 모든 독립변수 간의 관계가 선형인지 확인해야 한다. 독립변수와 종속변수 간의 관계가 선형인지 알아보려 Pearson 또는 Spearman 상관계수를 사용할 수 있다.

선형성을 테스트하는 데 사용할 수 있는 방법에는 White 검정, Terasvirta 검정, Reset 검정 등이 있다.

$$Y = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \cdots + \beta_p X_p + \varepsilon$$

또는 행렬 형태로 다음과 같이 쓸 수 있다.

$$Y = X\beta + \varepsilon$$

여기서

- Y = 종속 변수 벡터 $(n \times 1)$
- X = 독립 변수 행렬 $(n \times (p+1))$
- β = 회귀 모수 벡터 $((p+1) \times 1)$
- ε = 오차 벡터 $(n \times 1)$

β 모수를 추정하면 회귀 모델을 얻을 수 있다. 다음은 모수를 추정하는 공식이다.

$$\hat{\beta} = (X^T X)^{-1} X^T Y$$

3. 베이지안 선형회귀

베이지안 선형회귀는 베이지안 접근법을 사용하여 모수를 추정하는 회귀모델이다. 베이지안 접근법에서는 사전분포(prior), 가능도(likelihood)함수, 사후분포(posterior)가 존재한다. 모수 추정은 사전분포와 가능도함수를 곱해 사후분포를 계산함으로써 수행된다.

OLS 추정법을 사용하는 선형 회귀 모델에서는 오차가 정규분포를 따른다는 가정이 있다: $\varepsilon \sim N(0, \sigma^2)$. 오차가 정규분포를 따르면, $Y|X, \beta, \sigma^2$ 또한 정규분포를 따른다. 따라서

$$(Y|X, \beta, \sigma^2) \sim N(X\beta, \sigma^2)$$

이고 이 변수들의 확률밀도함수는 다음과 같다.

$$p(Y|X, \beta, \sigma^2) = \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left[-\frac{1}{2\sigma^2}(Y - X\beta)^T (Y - X\beta)\right]$$

위의 확률밀도함수를 바탕으로 우도함수는 다음과 같다.

$$p(Y|X, \beta, \sigma^2) = \prod_{i=1}^{n} \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left[-\frac{1}{2\sigma^2}(Y_i - X_i\beta)^2\right]$$

또는

$$p(Y|X, \beta, \sigma^2) = (\sigma^2)^{-n/2} \exp\left[-\frac{1}{2\sigma^2}(Y - X\beta)^T (Y - X\beta)\right]$$

베이지안 선형 회귀에서 사용할 수 있는 사전 분포 중 하나는 켤레 사전(conjugate prior)이다. 베이지안 회귀 모수 추정은 주변 사후를 반복적으로 계산하여 수행할 수 있다. 사후 분포는 사전 분포와 우도 함수를 곱해서 계산된다.

$$\text{Posterior} \propto \text{Likelihood} \times \text{Prior}$$

$$p(\beta, \sigma^2|Y, X) \propto p(Y|X, \beta, \sigma^2) p(\sigma^2) p(\beta|\sigma^2)$$

베이지안 접근법으로 회귀 모수를 추정하는 과정은 MCMC(Markov Chain Monte Carlo) 알고리즘을 사용하여 수행할 수 있다. MCMC에서 자주 사용되는 알고리즘 중 하나는 Gibbs 샘플링이다. 반복 과정을 통해 소각(burn-in) 조건을 만족할 때까지 파라미터를 추정한다.

4. 연구방법

UCI 머신러닝 저장소에서 얻은 데이터를 사용한다. 데이터는 12가지 다른 건물 모양에서 수집되었으며, 샘플 수는 768개이다. 에너지 효율성 사례를 기반으로 본 연구에서는 여러 독립 변수(X_1, X_2, X_3, X_4, X_5)와 단일 종속 변수(Y)를 사용한다.

- X_1 = 상대적 압축도(Relative Compactness)
- X_2 = 표면적(Surface Area)
- X_3 = 벽 면적(Wall Area)
- X_4 = 전체 높이(Overall Height)
- X_5 = 창 면적 비율(Glazing Area), 바닥 면적에 대한 백분율
- Y = 냉방 부하(Cooling Load), 공기 상태 유지를 위한 열 제거율

데이터는 먼저 빈도주의 방법으로 선형회귀 모델링을 수행하여 최소제곱법으로 모수를 추정했다. 또한 베이지안 방법으로 모델링되었다. 선형 회귀 모델의 베이지안 접근법을 구현하는 R 패키지는 `MCMCpack` 이다. 두 모델 결과를 평균제곱근오차(RMSE), 평균절대편차(MAD), 평균백분율오차(MAPE) 기준으로 비교하여 최적 모델을 판단했다.

5. 결과 및 논의

독립변수와 종속변수 간의 관계가 있는지 상관관계를 분석한 결과, 독립변수들이 종속변수와 상관관계가 있어서 선형회귀 분석을 수행했다.

최소제곱법을 사용한 다중선형회귀모델 결과는 다음과 같다.

$$Y = 97.76185 - 70.7877X_1 - 0.08825X_2 + 0.044682X_3 + 4.283843X_4 + 14.81797X_5$$

최소제곱법을 사용한 회귀모델에 대한 가정 검정 결과 잔차가 서로 독립이고, 같은 분포를 따르며, 정규분포를 가진다는 가정, 즉 IIDN 가정이 만족되지 않았다. 또한 VIF 테스트에서 다중공선성이 보였다.

베이지안 회귀모델을 사용해서 구한 결과는 다음과 같다.

$$Y = 97.7747 - 70.8027X_1 - 0.08824X_2 + 0.04466X_3 + 4.28452X_4 + 14.81861X_5$$

회귀계수는 빈도주의적 방법과 비교해서 큰 차이가 없었다.

최적방법을 결정하기 위해 평균제곱근오차(RMSE), 평균절대편차(MAD), 평균백분율오차(MAPE)를 비교한 결과는 다음과 같았다.

추정 방법	RMSE	MAD	MAPE
빈도주의	3.187969	2.247922	8.925759%
베이지안	3.187969	2.247842	8.925359%

비교 결과 RMSE 값은 빈도주의가 베이지안보다 약간 작았다. (역자 주: 그런데 데이터 값은 동일하기 때문에 소수점 7째 자리 이하에서 약간의 차이가 발생한 것으로 이해했습니다.)

반면 MAD와 MAPE 값은 베이지안이 더 작았다. 세 가지 기준에서 값이 더 작은 쪽이 더 좋은 모델을 의미한다. 세 기준 중 두 가지에서 베이지안 모델이 더 작은 값을 보였으므로, 이 경우 베이지안 선형회귀 모델을 사용하는 것이 더 적합하다.

또한 빈도주의 모델이 고전적 가정(IIDN)을 충족하지 못한 점도 고려하면, 베이지안 접근법이 더 나은 대안이다.

6. 결론

연구결과 빈도주의 접근법을 사용한 다중선형회귀모델은 다중공선성을 비롯한 고전적 가정을 충족하지 못했다. 그리고 평균제곱근오차는 미세하게 빈도주의 모델이 작았지만, 다른 2개의 값은 베이지안 모델이 작았기 때문에 베이지만 접근법을 사용한 선형회귀모델이 더 우수하다고 볼 수 있다.