Attention Is All You Need

Transformer의 핵심 원리

Vaswani et al.

NIPS 2017

순환 없이
문맥을 연결하는
시퀀스 모델

202485-010007 김동현

출발점: 순차 계산의 제약

RNN의 시간축 의존



이전 상태가 다음 상태의 계산을 결정

출력 생성은 자기회귀 방식이므로 토큰을 순차적으로 생성

Transformer

모든 위치의 관계를
행렬 연산으로 계산

학습 시 위치별 연산의
병렬화에 유리

Attention: 참조 정보를 가중합

현재 query 토큰

먹었다

각 토큰의 value를
가중치에 따라 혼합

참조 토큰	가중치
나는	0.2
사과를	0.5
먹었다	0.3

학습된 유사도를 반영한 새로운 표현

설명용 가상 예시: 어절을 토큰으로 단순화했으며 실제 학습된 가중치가 아님

Q · K · V: 같은 입력, 다른 역할

Self-attention에서는 동일한 입력 X에서 서로 다른 학습 선형변환



Q·K·V는 서로 다른 원문 단어 세트가 아니라 서로 다른 투영 결과

Scaled Dot-Product Attention

$$\text{Attention}(Q, K, V) = \text{softmax}(QK^T / \sqrt{d_k})\, V$$

01 비교

$QK^T / \sqrt{d_k}$

query와 key의 내적을
key 차원으로 스케일 조정

02 정규화

행별 softmax

각 query의 참조 가중치 합을
1로 정규화

03 혼합

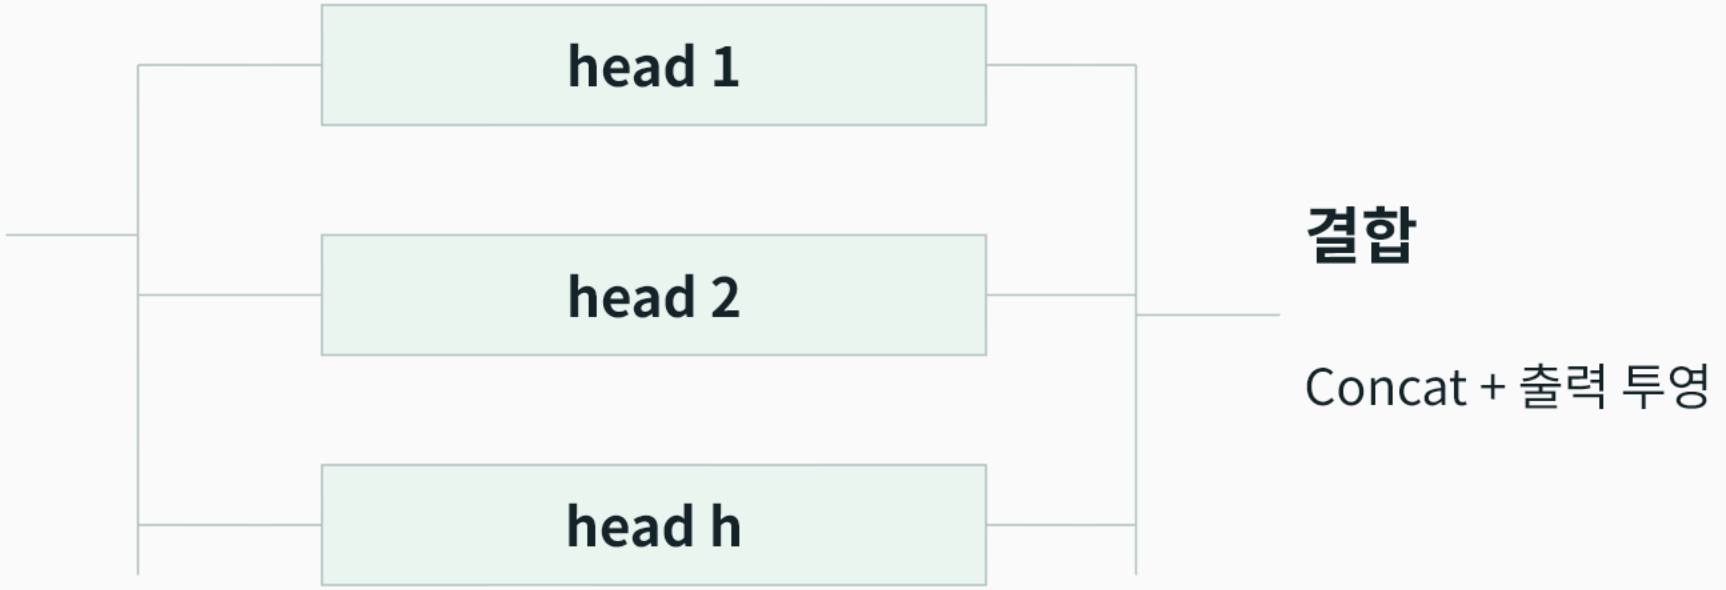
가중치 × V

value를 가중합해
문맥을 반영한 표현 생성

d_k: key 벡터의 차원 · 큰 내적으로 softmax가 지나치게 치우치는 현상을 완화

Multi-Head: 서로 다른 표현 공간

여러 학습 투영으로 attention을 병렬 계산한 뒤 결합



원문 base 모델: 8개 head · 각 head 차원 64 · 모델 차원 512

그림은 h개 head를 축약한 도식 · head별 역할을 미리 지정하지 않음

위치인코딩: 순서를 입력에 더하기

Self-attention만으로는 토큰의 순서를 별도로 알려주어야 함

토큰 임베딩 + **위치인코딩** 같은 차원끼리 더함

의미 정보

어떤 토큰인가

순서 정보

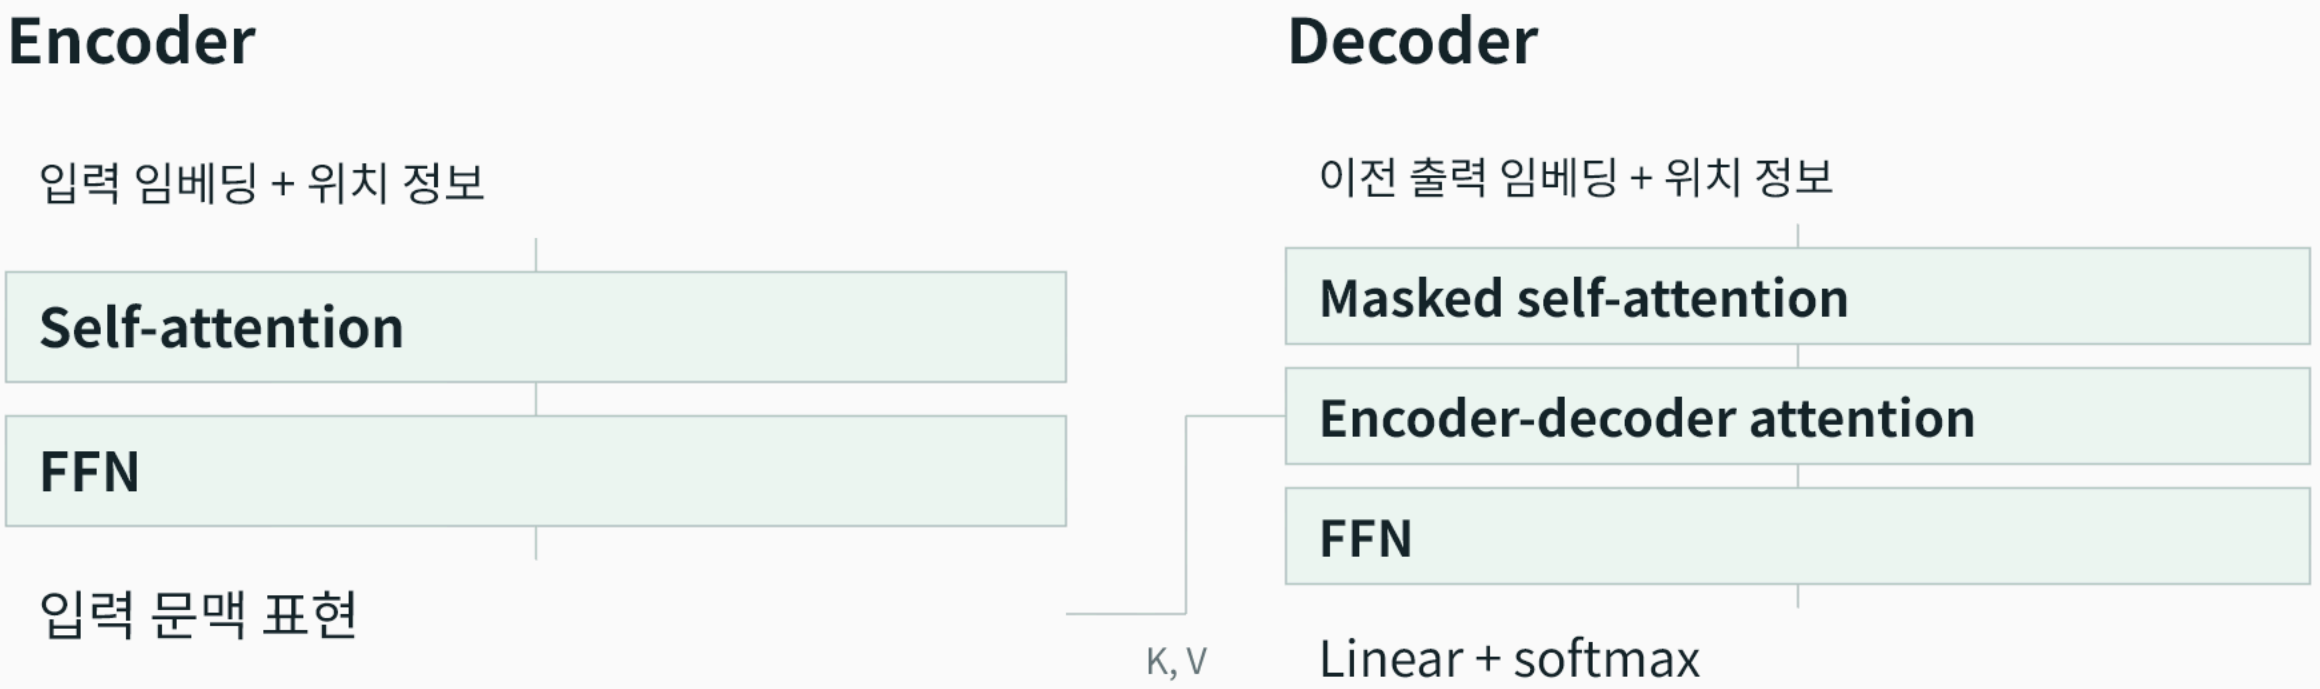
문장 안의 몇 번째 위치인가

원문: 차원별로 주기가 다른 sine·cosine 사용

위치 정보는 encoder와 decoder의 입력 임베딩에 더해짐

Transformer의 전체 구조

원문 base 모델을 요약한 encoder-decoder 구조



각 하위층: 잔차 연결 뒤 LayerNorm 적용 · FFN은 위치별 비선형 변환

Decoder: 미래를 가리고 입력을 참조

Masked self-attention

참조	t1	t2	t3
t1	허용	차단	차단
t2	허용	허용	차단
t3	허용	허용	허용

행: query 위치 · 열: 참조 위치

정답을 한 칸 밀어 입력
현재 입력까지 허용, 미래 위치 차단

Encoder-decoder attention

Decoder 상태 **Encoder 출력**

Q **K, V**

입력 문맥을 참조

생성 시에는 이전 출력으로
다음 토큰을 순차 예측

실험 결과와 계산 비용

WMT 2014 영어→독일어 · newstest2014 · 원문 Table 2

모델	BLEU
GNMT + RL	24.6
ConvS2S	25.16
Transformer base	27.3
Transformer big	28.4

BLEU: 높을수록 좋은 번역 평가지표

n: 시퀀스 길이 · d: 표현 차원 · BLEU는 백분율이나 정답률이 아님

긴 입력의 비용

$$O(n^2 d)$$

전체 self-attention의
층당 계산량

토큰 쌍의 수는 n^2로 증가
생성 단계의 순차성도 남음

정리

관계를 계산해 문맥을 만든다

Attention

입력에 따라 계산한 가중합

Transformer

위치 정보·FFN·잔차 연결과 결합

의의와 한계

학습 병렬화, 긴 입력과 생성의 비용

출처: Vaswani et al., Attention Is All You Need, NIPS 2017 · arXiv:1706.03762